



ROS Mobil Navigasyon Başarısızlıklarında Büyük Dil Modeli Tabanlı Görev Seviyesi Kurtarma ve Yeniden Planlama

Merve Tutar * 

Ankara Üniversitesi, Yapay Zeka Enstitüsü, Yapay Zeka ve Robotik Tezli Yüksek Lisans, Ankara, Türkiye,
mervetutar78@gmail.com

* Corresponding Author

Submitted: 14.06.2026

Accepted: DD.MM.YYYY

Published: DD.MM.YYYY



Özet:

Bu çalışmada, klasik ROS mobil robot navigasyonunun görev seviyesi başarısızlık durumlarında büyük dil modeli (LLM) tabanlı açıklanabilir bir kurtarma katmanı ile desteklenmesi ele alınmaktadır. Önerilen sistemde düşük seviye hareket yürütme ve lokal engelden kaçınma ROS move_base tarafından gerçekleştirilirken, LLM yalnızca ABORTED, ilerleme kaybı veya aktif hedefin erişilemez hale gelmesi gibi durumlarda devreye alınmaktadır. TurtleBot3 Burger, ROS Noetic ve Gazebo ortamında A-B-C görev dizisi tanımlanmış; B noktası zorunlu kontrol noktası olarak modellenmiştir. B bölgesinin $0.8 \text{ m} \times 3.5 \text{ m} \times 0.6 \text{ m}$ boyutlu dinamik bir engelle kapatıldığı deneylerde yalnızca move_base kullanılan temel sistem üç tekrarın hiçbirinde görevi tamamlayamamıştır. Buna karşılık önerilen LLM destekli recovery sistemi üç tekrarın tamamında alternatif waypointler üretmiş, robotu final C hedefine ortalama 0,35 m hata ile ulaştırmış ve her denemede yalnızca bir kurtarma döngüsü yeterli olmuştur. Sonuçlar, LLM'nin düşük seviye planner yerine görev seviyesi hata yorumlama ve yeniden planlama katmanı olarak kullanılmasının mobil robot navigasyonunda işlevsel ve açıklanabilir bir hibrit yaklaşım sunduğunu göstermektedir.

Anahtar Kelimeler: Büyük Dil Modelleri, Görev Seviyesi Kurtarma, Mobil Robotik, ROS Navigasyon

© 2026 Published by peer-reviewed open access scientific journal, Computers and Informatics (C&I) at DergiPark
(dergipark.org.tr/ci)

Cite this paper as: Tutar, M., ROS mobil navigasyon başarısızlıklarında büyük dil modeli tabanlı görev seviyesi kurtarma ve yeniden planlama, Computers and Informatics, YYYY; v(i); pp-pp, <https://doi.org/10.62189/ci.00000000>

1. GİRİŞ

Otonom mobil robotlar genellikle algılama, konumlandırma, haritalama, global planlama, lokal planlama ve hareket kontrolü bileşenlerinden oluşan katmanlı navigasyon mimarilerine dayanır. Robot Operating System (ROS), bu tür mimarilerin uygulanması için yaygın kullanılan açık kaynaklı bir ekosistem sunmaktadır [1]. ROS 1 ortamında move_base paketi, hedef poz alan, global rota oluşturan ve lokal engelden kaçınma davranışlarını ilgili planlayıcıya devreden temel navigasyon bileşenlerinden biridir [2].

Bununla birlikte, robotik görevlerin tamamı yalnızca geometrik hedeflerden ibaret değildir. Denetim, güvenlik, lojistik veya servis robotları gibi alanlarda ara hedefler; kontrol noktası, gözlem pozisyonu, teslim noktası veya güvenlik doğrulama bölgesi gibi göreve özgü anlamlar taşıyabilir. Böyle bir kontrol noktası fiziksel olarak kapandığında lokal planlayıcı engelin etrafında dolaşmaya çalışabilir; ancak görev düzeyinde kontrol noktasının tamamlanıp tamamlanmadığı, atlanıp atlanamayacağı veya eşdeğer bir alternatif nokta seçilip seçilemeyeceği klasik geometrik planlayıcının kapsamı dışında kalır.

Bu çalışmanın temel motivasyonu, büyük dil modellerinin (LLM) mobil robotlarda düşük seviye engelden kaçınma algoritması olarak değil, görev seviyesi hata yorumlama ve yeniden planlama katmanı olarak kullanılmasının incelenmesidir. Önerilen mimaride LiDAR, robot konumu ve move_base durumları kullanılarak hata olayı belirlenir; LLM'ye ise yapılandırılmış bir görev raporu gönderilir. LLM çıktısı doğrudan motor komutu değildir; yalnızca doğrulanabilir ara hedeflerden oluşan bir recovery planıdır.

Çalışmanın katkıları üç başlıkta özetlenebilir. İlk olarak, move_base durumları, hedef mesafesi ve aktif hedef engellenmesi bilgisini birlikte kullanan görev seviyesi hata tespit yapısı sunulmuştur. İkinci olarak, LLM'nin serbest metin üretiminden ziyade sınırlı waypoint listesi ürettiği açıklanabilir bir recovery mimarisi önerilmiştir. Üçüncü olarak, aynı engel senaryosu altında yalnızca move_base kullanılan temel sistem ile LLM destekli recovery sistemi deneysel olarak karşılaştırılmıştır.

2. İLGİLİ ÇALIŞMALAR

LLM tabanlı robotik sistemler, son yıllarda doğal dil ile görev tanımlama, yüksek seviye planlama, beceri seçimi ve hata yorumlama gibi başlıklarda yoğun biçimde incelenmektedir. ROS-LLM çalışması, LLM ajanlarının ROS action ve service çağrılarıyla bütünleştirilerek davranış dizileri veya davranış ağaçları üretebildiğini göstermiştir [5]. Bu yaklaşım, LLM'nin doğrudan motor komutu üretmek yerine robot sisteminin üst seviye karar katmanında kullanılmasını desteklemektedir.

Agentic LLM tabanlı robot sistemlerine ilişkin güncel incelemeler, bu sistemlerin yalnızca görev başarısıyla değil; güvenlik, açıklanabilirlik, denetlenebilirlik ve insan gözetimi açısından da değerlendirilmesi gerektiğini vurgulamaktadır [6]. Benzer biçimde, otonom robotik için LLM entegrasyonunu ele alan çalışmalar, navigasyon ve manipülasyon görevlerinde LLM'nin bağlamsal karar desteği sağlayabildiğini, ancak gecikme, güvenlik ve doğrulama sorunlarının sistem tasarımının temel parçası olması gerektiğini belirtmektedir [9,10]. LLM tabanlı beceri keşfi çalışmaları, dil modellerinin robot için yeni görevler ve beceriler önerme kapasitesine sahip olduğunu ortaya koymuştur [8].

Navigasyon özelinde, semantik keşif ve beceri orkestrasyonu çalışmaları LLM'ye ortam bilgisi, karar geçmişi ve sınırlı eylem uzayı verilmesinin güvenilirliği artırdığını göstermektedir [7]. Gecikme farkındalıklı benchmark çalışmaları ise LLM tabanlı robot navigasyonunda yalnızca hedefe ulaşma oranının değil, yanıt süresi, yol kalitesi ve planner seçiminin de ölçülmesi gerektiğini ortaya koymaktadır [11]. Bu makale, söz konusu literatürden farklı olarak LLM'yi başlangıçtan itibaren ana navigasyon planlayıcısı olarak değil, klasik move_base başarısız olduğunda devreye giren görev seviyesi recovery katmanı olarak konumlandırmaktadır.

3. YÖNTEM

Önerilen sistem, klasik ROS navigasyon yığını ile LLM tabanlı görev seviyesi recovery katmanını birlikte kullanan hibrit bir mimaridir. Robotun normal hareketi sırasında hedefler move_base action sunucusuna gönderilir. move_base hedefe ulaşabiliyorsa LLM çağrılmaz. Böylece basit lokal engellerde klasik navigasyonun yeterli olduğu durumlarda gereksiz LLM maliyeti ve gecikmesi oluşmaz.



Şekil 1. Önerilen hibrit mimaride klasik ROS navigasyon yalnızca görev başarısızlığı durumlarında LLM destekli recovery katmanına devredilmektedir.

3.1. Görev Modeli ve Başarısızlık Tespiti

Deneyisel görev A-B-C dizisi olarak tanımlanmıştır. A başlangıç noktası (-3.0, 0.0), B zorunlu kontrol noktası (0.0, 0.0) ve C final hedef (3.0, 0.0) olarak belirlenmiştir. Robotun B noktasına yalnızca yakınından geçmesi değil, aktif kontrol hedefini tamamlaması beklenmektedir. B noktasının dinamik engel tarafından kapatılması bu nedenle yalnızca lokal engel değil, görev seviyesi başarısızlık olarak ele alınmıştır.


Hata tespit katmanı üç tür sinyali izler: move_base durum kodu, robotun hedefe ilerleme davranışı ve aktif hedefin engellenip engellenmediği. move_base ABORTED veya REJECTED durumuna düştüğünde, robot belirli süre boyunca hedefe yaklaşmadığında ya da aktif hedefin çevresi engel tarafından işgal edildiğinde mevcut hedef iptal edilir ve LLM recovery süreci başlatılır. Bu yapı, LLM'nin yalnızca gerekli durumlarda çağrılmasını sağlar.

3.2. LLM Recovery Planı

LLM'ye gönderilen rapor; hata tipi, robotun güncel konumu, aktif hedef, final hedef, engel tahmini ve navigasyon durumu gibi alanları içerir. Modelden istenen çıktı, açıklama ve strateji alanlarına ek olarak sınırlı sayıda ara hedeften oluşan JSON benzeri bir waypoint listesidir. Waypointler harita sınırları ve görev hedefleri açısından doğrulandıktan sonra move_base'e sırayla gönderilir. Bu nedenle LLM çıktısı doğrudan hız komutu veya çarpışma önleme kararı üretmez; yalnızca üst seviye görev planını revize eder.

4. DENEYSEL KURULUM

Deneyler Ubuntu 20.04, ROS Noetic, Gazebo Classic [12], TurtleBot3 Burger modeli [13] ve move_base tabanlı navigasyon yığını (küresel planlama için A* [4], lokal planlama için DWA [3]) ile gerçekleştirilmiştir. Simülasyon haritası duvarlarla çevrili dikdörtgen bir iç mekan olarak tasarlanmıştır. B kontrol noktasını engellemek için 0.8 m × 3.5 m × 0.6 m boyutunda dinamik bir kutu/duvar engeli kullanılmıştır. LLM çağrıları google/gemma-4-31b-it:free modeliyle yapılmıştır.



Şekil 2. Gazebo ortamında görev ortamı, dinamik engel ve recovery sürecinin simülasyon görüntüleri.

İki deney grubu oluşturulmuştur. İlk grupta yalnızca move_base kullanılmış ve LLM devre dışı bırakılmıştır. Bu grup, B kontrol noktasının kapatıldığı durumda klasik navigasyonun temel performansını göstermektedir. İkinci grupta aynı engel senaryosu LLM destekli recovery sistemi ile tekrarlanmıştır. Her grup üç kez çalıştırılmış; başarı durumu, süre, yol uzunluğu, final hedef hatası ve LLM recovery sayısı kaydedilmiştir.


5. BULGULAR

Baseline deneylerinde robot engelli B kontrol noktasına yalnızca move_base ile yönlendirilmiştir. Üç tekrarın hiçbirinde görev başarıyla tamamlanamamıştır. Robot engelin çevresinde lokal hareketler üretmiş, ancak B kontrol noktasını tamamlayamamış ve final C hedefine geçememiştir. Bazı tekrarlar move_base aktif kalmasına rağmen 60 saniyelik süre sınırı içinde başarı koşulu sağlanmadığından deneme başarısız kabul edilmiştir.

LLM destekli recovery deneylerinde ise sistem B hedefinde ilerleme kaybı veya hedef engellenmesi durumunu tespit etmiş, mevcut hedefi iptal etmiş ve LLM'den alternatif waypoint planı istemiştir. Üç tekrarın tamamında LLM bir recovery planı üretmiş ve robot final C hedefine ulaşmıştır. Deney kayıtlarında LLM recovery sayısı her başarılı denemede bir olarak ölçülmüştür.

Table 1. Deney sonuçlarının özet karşılaştırması

Deney grubu	Tekrar	Başarı	Başarı oranı	Ortalama süre (sn)	Ortalama yol (m)	Final C hatası (m)	LLM recovery
Baseline: move_base only	3	0/3	%0	60.10 ± 0.04	11.36 ± 0.17	2.63 ± 0.48	0
Önerilen: move_base + LLM recovery	3	3/3	%100	61.07 ± 4.59	10.43 ± 1.13	0.35 ± 0.02	1 / deneme



Şekil 3. Baseline ve LLM destekli recovery deneylerinde robotun izlediği yolların karşılaştırması. Turuncu kesikli çizgi LLM tarafından üretilen waypoint planını göstermektedir.

Sonuçlar, baseline sistemin başarı oranının %0, LLM destekli recovery sisteminin ise %100 olduğunu göstermektedir. BDM destekli sistemde ise 3/3 yinelemede görev başarıyla tamamlanmıştır. Ortalama görev süresi 61,07 s, C nihai hedefine ortalama uzaklık 0,35 m olarak ölçülmüştür. Her yinelemede tam olarak bir BDM kurtarma döngüsü gerçekleşmiştir. Ortalama yol uzunluğu 10,43 m olup temel sisteme (11,36 m) kıyasla daha kısa çıkmıştır. Bu sonuç, BDM'nin ürettiği alternatif güzergahın hedefe daha kısa bir çizgide ulaştığını göstermektedir. Başarı oranı açısından iki sistem arasındaki fark mutlak (%0'a karşı %100) olup bu denli küçük bir örnek kümesinde istatistiksel test uygulanmasına gerek kalmamıştır.

Üç yinelemede BDM tarafından üretilen güzergah planları incelendiğinde, modelin her seferinde tutarlı bir strateji geliştirdiği görülmektedir. Model, hata raporundaki engel koordinatı, ACTIVE_GOAL_BLOCKED bayrağı ve sensör özetini bütüncül biçimde yorumlayarak B kontrol noktasının (~0,0) büyük engel tarafından işgal edildiğini çıkarsamamış ve y ekseninde yaklaşık +1,0 birim kaydırmayla alternatif geçiş noktaları üretmiştir. Birinci yinelemede üretilen güzergah planı [-1,0; 1,0] → [1,0; 1,0] → [3,0; 0,0] koordinatlarından oluşmakta olup bu üç waypoint move_base tarafından sırasıyla başarıyla uygulanmıştır. BDM, yalnızca waypoint koordinatlarını değil, Türkçe strateji açıklaması da üretmiş; bu açıklama kurtarma kararını insan tarafından okunabilir biçimde belgelemiştir.

Şekil 3'te temel sistem ve BDM destekli sistemin birinci yinelemeye ait örnek yörüngeleri gösterilmektedir. Temel sistemde robotun B kontrol noktası etrafında döngüsel hareket sergilediği ve 60 saniyeyi süre aşımıyla tamamladığı görülmektedir. BDM destekli sistemde ise başarısızlık tespitinin ardından üretilen waypoint'lerin etkin biçimde izlendiği ve C hedefine ulaşıldığı izlenmektedir.

Bu bulgu, LLM'nin klasik lokal planlayıcı yerine geçmeden, yalnızca görev seviyesi başarısızlık anında recovery planı üretmesiyle görevin tamamlanabildiğini göstermektedir.

6. TARTIŞMA

Deney sonuçları, LLM'nin mobil robot navigasyonunda en uygun rolünün düşük seviye engelden kaçınma değil, görev seviyesi karar desteği olduğunu göstermektedir. Basit ve dolanılabılır engellerde move_base lokal planlayıcısı zaten etkili davranabilir. Buna karşın B gibi zorunlu ve anlamlı bir kontrol noktasının anlık kapanması durumunda, sorun artık yalnızca geometrik bir yol bulma problemi değil, görevin yeniden yorumlanması problemidir.

Önerilen yaklaşımın güçlü yönü, LLM çağrısını yalnızca hata durumlarına sınırlamasıdır. Bu sayede model gecikmesi normal navigasyon akışını etkilemez. Ayrıca LLM çıktısının waypoint seviyesinde tutulması, güvenlik ve doğrulanabilirlik açısından doğrudan hız komutu üretimine göre daha kontrollü bir yapı sağlar. Bununla birlikte bu çalışma bazı sınırlılıklar barındırmaktadır.

Deneyler yalnızca simülasyon ortamında yürütülmüş; gerçek donanım doğrulaması gerçekleştirilmemiştir. Her koşuldaki yinleme sayısının ($n=3$) istatistiksel güç açısından yetersiz kaldığı kabul edilmelidir. Senaryonun sabit bir görev sırası ($A \rightarrow B \rightarrow C$) ve tek bir engel geometrisine dayanması, sistemin farklı ortamlara genellenebilirliğini kısıtlamaktadır. Gerçek robot deneyleri, farklı haritalar, farklı engel türleri ve farklı LLM modelleriyle daha kapsamlı değerlendirme yapılması gerekmektedir.

7. SONUÇ

Bu çalışmada ROS move_base başarısızlıklarında devreye giren LLM destekli görev seviyesi recovery mimarisi sunulmuştur. TurtleBot3 ve Gazebo ortamında yapılan deneylerde, B kontrol noktasının engellenmesi durumunda yalnızca move_base kullanılan baseline sistem üç tekrarın hiçbirinde görevi tamamlayamazken, önerilen sistem üç tekrarın tamamında final C hedefine ulaşmıştır. Elde edilen bulgular, LLM'lerin mobil robotlarda path planner yerine açıklanabilir ve denetlenebilir bir görev seviyesi yeniden planlama katmanı olarak kullanılmasının daha uygun olduğunu göstermektedir.

Funding

Bu çalışma için herhangi bir dış finansal destek alınmamıştır.

Conflict of Interest

Herhangi bir çıkar çatışması yoktur.

Data and Code Availability

ROS paketi, Gazebo dünya dosyaları, deney günlükleri ve yörünge grafikleri makul talep üzerine paylaşılabilir. Deneyler yalnızca simülasyon ortamında yürütülmüştür.

KAYNAKLAR

- [1] Quigley M, Conley K, Gerkey B, Faust J, Foote T, Leibs J, et al. ROS: an open-source Robot Operating System. In: ICRA Workshop on Open Source Software; 2009.
- [2] Marder-Eppstein E, Berger E, Foote T, Gerkey B, Konolige K. The office marathon: robust navigation in an indoor office environment. In: Proceedings of the IEEE International Conference on Robotics and Automation; 2010. pp. 300-307.
- [3] Fox D, Burgard W, Thrun S. The dynamic window approach to collision avoidance. IEEE Robotics & Automation Magazine 1997; 4(1):23-33.
- [4] Hart PE, Nilsson NJ, Raphael B. A formal basis for the heuristic determination of minimum cost paths. IEEE Transactions on Systems Science and Cybernetics 1968; 4(2):100-107.
- [5] Mower CE, Wan Y, Yu H, Grosnit A, Gonzalez-Billandon J, Zimmer M, et al. A robot operating system framework for using large language models in embodied AI. Nat Mach Intell. 2026;8(3):313-325. DOI: 10.1038/s42256-026-01186-z.
- [6] Raptis EK, Kapoutsis AC, Kosmatopoulos EB. Agentic LLM-based robotic systems for real-world applications: a review on their agenticness and ethics. Frontiers in Robotics and AI 2025; 12: 1605405. DOI: 10.3389/frobt.2025.1605405.
- [7] Syarubany AHM, Rahmani FZ, Widiyanto T. LLM-based agentic exploration for robot navigation and manipulation with skill orchestration. arXiv preprint 2026; arXiv:2601.00555.
- [8] Zhao X, Weber C, Wermter S. Agentic skill discovery. arXiv preprint 2024; arXiv:2405.15019.
- [9] Liu Y, Sun Q, Kapadia DR. Integrating large language models into robotic autonomy: a review of motion, voice, and training pipelines. AI 2025; 6(7):158. DOI: 10.3390/ai6070158.
- [10] Wang J, Shi E, Hu H, Ma C, Liu Y, Wang X, et al. Large language models for robotics: opportunities, challenges, and perspectives. Journal of Automation and Intelligence 2025; 4: 52-64. DOI: 10.1016/j.jai.2024.12.003.
- [11] Das M, Hussain Z, Nawaz M. Latency-aware benchmarking of large language models for natural-language robot navigation in ROS 2. Sensors 2026; 26(2):608. DOI: 10.3390/s26020608.
- [12] Koenig N, Howard A. Design and use paradigms for Gazebo, an open-source multi-robot simulator. In: IEEE/RSJ International Conference on Intelligent Robots and Systems; 2004. pp. 2149-2154. DOI: 10.1109/IROS.2004.1389727.
- [13] ROBOTIS. TurtleBot3 [Internet]. 2017 [Eriřim: 14 Haziran 2026]. Eriřim adresi: <https://emanual.robotis.com/docs/en/platform/turtlebot3/overview/>